WEKA 3-5-5 Explorer 使用者指南

原文版本 **3.5.5**
翻譯 王娜
校對 **C6H5NO2**
Pentaho 中文討論群
組 **QQ** 群：**12635055** 論壇：
http://www.bipub.org/bipub/index.asp
http://bbs.wekacn.org/

目　　錄

啓動 WEKA

WEKA中新的功能表驅動的 GUI 繼承了老的 GUI 選擇器（類 weka.gui.GUIChooser） 的功能。它的MDI（ “多重文件介面” ）外觀，讓所有打開的視窗更加明瞭。

這個功能表包括六個部分。

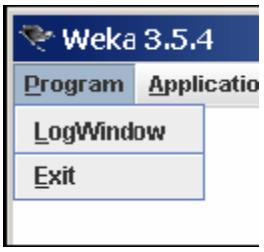

1. **Program**
   - **LogWindow** 打開一個日誌視窗，記錄輸出到 stdout 或 stderr 的內容。在 MS Windows 那樣的環境中，WEKA 不是從一個終端啓動，這個就比較有用。
   - **Exit** 關閉WEKA。

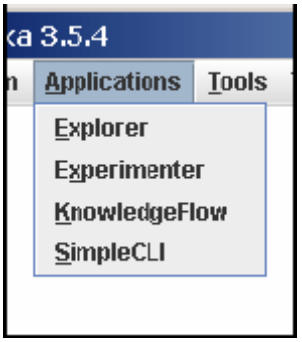

2. **Applications** 列出 WEKA 中主要的應用程式。
   - **Explorer** 使用 WEKA 探索資料的環境。（本文檔的其它部分將詳細介紹這個環境）
   - **Experimenter** 運行演算法試驗、管理演算法方案 之間的統計檢驗的環境。
   - **KnowledgeFlow** 這個環境本質上和 Explorer 所支持的功能是一樣的，但是它有一個可以拖放的介面。它有一個優勢，就是支持增量學習（incremental learning）。
   - **SimpleCLI** 提供了一個簡單的命令列介面，從而可以在沒有自帶命令列的作業系統中直接執行 WEKA 命令。
3. **Tools** 其他有用的應用程式。
   - **ArffViewer** 一個 MDI 應用程式，使用電子表格的形式來查看 ARFF 檔。
   - **SqlViewer** 一個 SQL 工作表，用來通過 JDBC 查詢資料庫。
   - **EnsembleLibrary** 生成集成式選擇（Ensemble Selection）[5] 所需設置的介面。

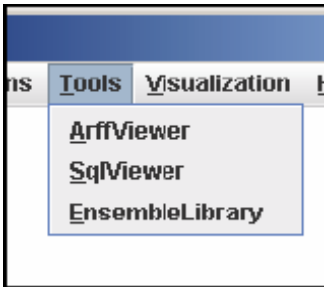

4. **Visualization** WEKA 中資料視覺化的方法。
   - **Plot** 作出資料集的二維散點圖。
   - **ROC** 顯示預先保存的 ROC 曲線。

- **TreeVisualizer** 顯示一個有向圖，例如一個決策樹。
- **GraphVisualizer** 顯示 XML、BIF 或 DOT 格式的圖片，例如貝葉斯網路（Bayesian network）。
- **BoundaryVisualizer** 允許在二維空間中對分類器的決策邊界進行視覺化。

5. **Windows** 所有已打開的視窗都列在這裡。
   - **Minimize** 最小化所有當前的視窗。
   - **Restore** 還原所有最小化過的視窗。
6. **Help** WEKA 的線上資源可以從這裡找到。
   - **Weka homepage** 打開一個流覽器視窗，顯示 WEKA 的主頁。
   - **Online documentation** 連結到 WekaDoc 維琪文檔 [4]。
   - **HOWTOs, code snippets, etc.** 通用的 WekaWiki [3]，包括大量的例子，以及開發和使用 WEKA 的基本知識（HOWTO）。
   - **Weka on Sourceforge** WEKA 項目在 Sourceforge.net 的主頁。
   - **SystemInfo** 列出一些關於 Java/WEKA 環境的資訊，例如 CLASSPATH。
   - **About** 不光彩的“About”窗口。

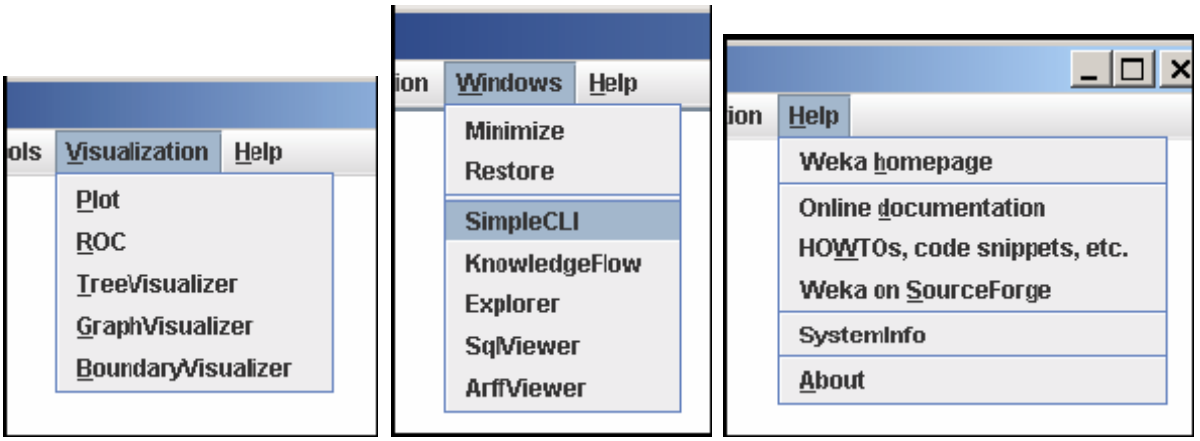

如果從終端啓動 WEKA，會有一些文字在終端視窗中出現。這些文字是可以忽略的，除非某些東西出錯了——這時它可以說明找到錯誤的原因。（LogWindow 也可以顯示那些資訊。）

這份文檔也可以從線上的 WekaDoc Wiki [4] 中找到，它將集中闡述如何使用 Explorer，而不會逐個解釋 WEKA 中的資料預處理工具和學習演算法。要獲得關於各種篩選 器（filter）和學習演算法的更多資訊，可參考 Data Mining [2] 一書。

1 WEKA Explorer

1.1 標籤頁

在窗口的頂部，標題列下是一排標籤。當 Explorer 首次啓動時，只有第一個標籤頁是活動的；其他均是灰色的。這是因爲在探索資料之前，必須先打開一個資料集(可能還要對它進行預處理)。

所有的標籤頁如下所示：

1. **Preprocess.** 選擇和修改要處理的資料。
2. **Classify.** 訓練和測試關於分類或回歸的學習方案。
3. **Cluster.** 從數據中學習聚類。
4. **Associate.** 從資料中學習關聯規則。
5. **Select attributes.** 選擇資料中最相關的屬性。
6. **Visualize.** 查看資料的互動式二維圖像。 這些標籤被啓動後，點擊它們可以在不同的標籤頁面上進行切換，而每一個頁面上可以執行對應的操作。不管位於哪個頁面，視窗的底部區域(包括狀態列、log 按鈕和 Weka 鳥)仍然可見。

1.2 狀態列

狀態（Status）欄出現在視窗的最底部。它顯示一些資訊讓你知道正在做什麼。例如，如果 Explorer 正忙於裝載一個檔，狀態列就會有通知。

提示 — 在狀態列中的任意位置右擊滑鼠將會出現一個小功能表。這個功能表給了你兩個選 項：

1. **Memory Information.** 在 log 欄中顯示 WEKA 可用的記憶體量。
2. **Run garbage collector.** 強制運行 Java 垃圾回收器，搜索不再需要的記憶體空間 並將之釋放，從而可爲新任務分配更多的記憶體。注意即使不強制運行，垃圾回收 也是一直作爲幕後工作在運行的。

1.3 Log 按鈕

點擊這個按鈕，會出現一個單獨的視窗，包含一個可拖動的文本區域。文本的每一行被加了一個時間戳記，顯示了它進入日誌（log）的時間，一旦在WEKA 中執行某種操作時， 該日誌就會記錄發生了什麼。對於使用命令列或者 SimpleCLI 的人，日誌也將完整地記 錄分類，聚類，特徵提取等任務的設置字元，使得它們可被複製/粘貼到其它地方。但關 於資料集和 class 屬性[1]的選項仍然要由使用者給出（例如，分類器（classifier）的 –t，或 者篩選器的 –i 和 -o）

1.4 WEKA 狀態圖示

狀態列的右邊是 WEKA 狀態圖示。當不運行任何進程時，WEKA鳥會坐下並打一個小盹。×符號旁的數字顯示了正運行的併發進程的數量。當系統空閒時，它是零，而當進程的數量增長時，它也會增長。任意進程啓動後，小鳥會站起來並到處活動。如果它仍然是站著的，但是很長時間內不動，那麼它生病了：某個地方出錯了！在這種情況下，應該重新啓動 WEKA Explorer。

---

[1] 在分類或回歸任務中，class 屬性是預設的目標變數。注意這與下文中的分類型屬性不是一個概念—譯注。

2 預處理

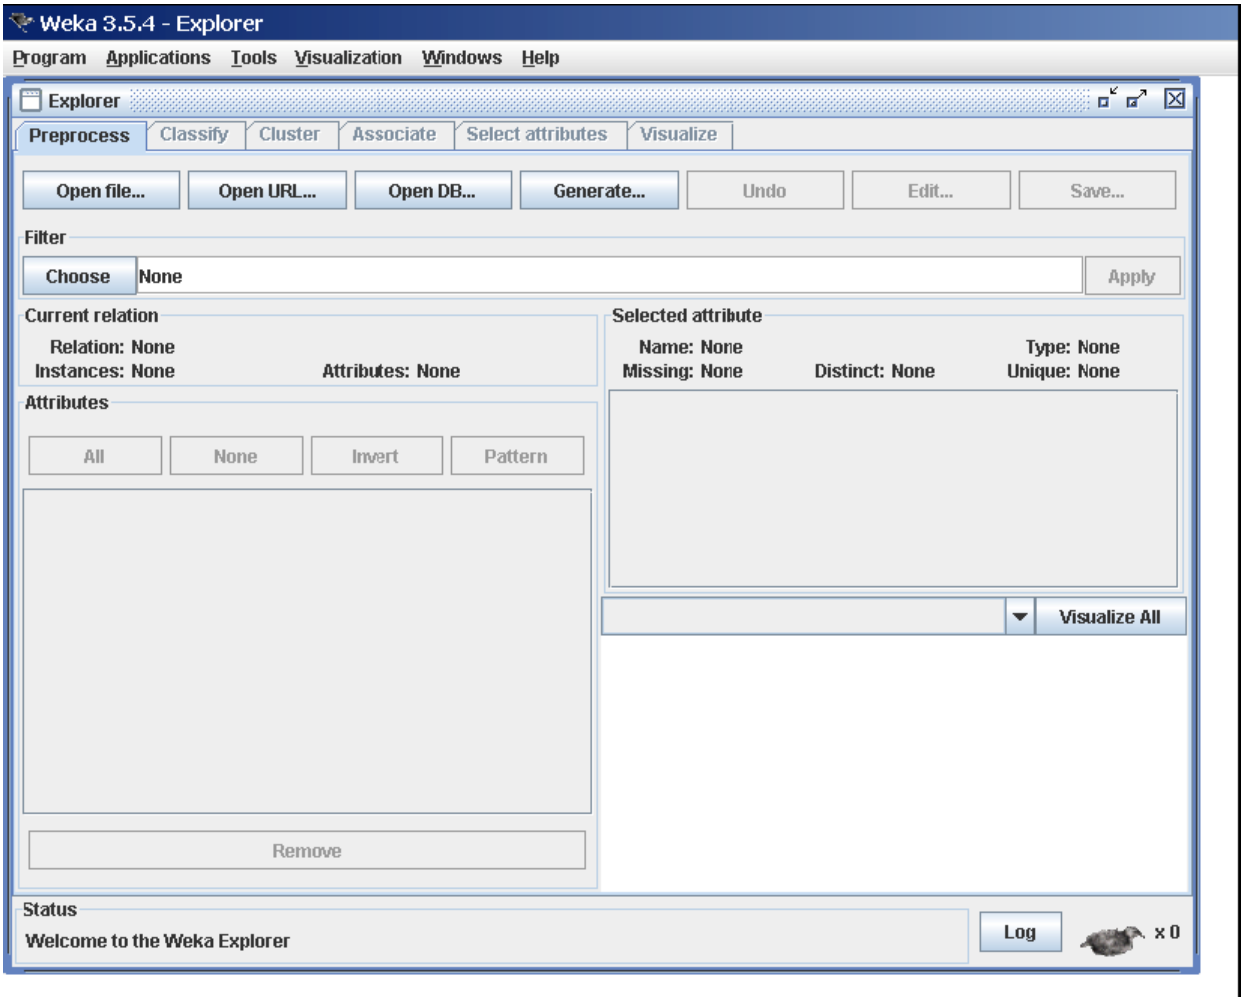

2.1 載入數據

預處理頁頂部的前4個按鈕用來把資料載入WEKA：

1. **Open file....** 打開一個對話方塊，允許你流覽本地檔案系統上的資料檔案。
2. **Open URL....** 請求一個存有資料的 URL 位址。
3. **Open DB....** 從資料庫中讀取資料 (注意，要使之可用，可能需要編輯 weka/experiment/ DatabaseUtils.props 中的文件)
4. **Generate....** 從一些資料生成器（DataGenerators）中生成人造資料。

使用 **Open file...** 按鈕可以讀取各種格式的檔：WEKA 的 ARFF 格式，CSV 格式，C4.5 格式，或者序列化的實例[2]格式。ARFF 檔通常副檔名是.arff，CSV 文件副檔名是 .csv，C4.5 文件副檔名是 .data 和 .names ，序列化的實例物件副檔名爲 .bsi。

2.2 當前關係

載入資料後，預處理面板就會顯示各種資訊。**Current relation** 一欄(“current relation” 指目前裝載的資料，可理解爲資料庫術語中單獨的關係表）有3個條目：

1. **Relation.** 關係的名稱，在它裝載自的檔中給出。使用篩選器（下文將詳述）將修改關係的名稱。

[2] 只有本段文字中的“實例”是 JAVA 語言中實例的概念；而後文中的“實例”都將指資料集中的記錄—譯注。

2. **Instances.** 資料中的實例(或稱資料點/記錄) 的個數。
3. **Attributes.** 資料中的屬性(或稱特徵) 的個數。

2.3 處理屬性

在 **Current relation** 一欄下是 **Attributes**（屬性）欄。有四個按鈕，其下是當前關系中的屬性清單。該列表有3列：

1. **No..** 一個數位，用來標識資料檔案中指定的各屬性的順序。
2. 選擇框**.** 允許勾選關係中呈現的各屬性。
3. **Name.** 資料檔案中聲明的各屬性的名稱。

當點擊屬性清單中的不同行時，右邊 **Selected attribute** 一欄的內容隨之改變。這一欄給出了清單中當前高亮顯示的屬性的一些描述：

1. **Name.** 屬性的名稱，和屬性清單中給出的相同。
2. **Type.** 屬性的類型，最常見的是分類型（Nominal）和數值型（Numeric）。
3. **Missing.** 資料中該屬性缺失(或者未指定)的實例的數量(及百分比)。
4. **Distinct.** 資料中該屬性包含的不同值的數目。
5. **Unique.** 唯一地擁有某值的實例的數目（及百分比），這些實例每個的取值都和別的不一樣。

在這些統計量的下面是一個清單，根據屬性的不同類型，它顯示了關於這個屬性中儲存的值的更多資訊。如果屬性是分類型的，清單將包含該屬性的每個可能值以及取那個值的實例的數目。如果屬性是數值型的，列表將給出四個統計量來描述資料取值的分佈—最小值、最大值、平均值和標準差。在這些統計量的下方，有一個彩色的長條圖，根據長條圖上方一欄所選擇的 class 屬性來著色。(在點擊時，該欄將顯示一個可供選擇的下拉清單。)注意僅有分類型的 class 屬性才會讓長條圖出現彩色。最後，若點擊 **Visualize All** 按鈕，將在一個單獨的視窗中顯示資料集中所有屬性的長條圖。

回到屬性清單，開始時所有的選擇框都是沒有被勾選的。可通過逐個點擊來勾選/取消。以上的4個按鈕也可用於改變選擇：

1. **All.** 所有選擇框都被勾選。
2. **None.** 所有選擇框被取消（沒有勾選）。
3. **Invert.** 已勾選的選擇框都被取消，反之亦然。
4. **Pattern.** 讓使用者基於 Perl 5 規則運算式來選擇屬性。例如，用 *_id 選擇所有名 稱以 _id 結束的屬性。

選中了想要的屬性後，可通過點擊屬性清單下的 **Remove** 按鈕刪除他們。注意可通過點擊位於 Preprocess 面板的右上角的 **Edit** 按鈕旁的 **Undo** 按鈕來取消操作。

2.4 使用篩選器3

在預處理階段，可以定義篩選器來以各種方式對資料進行變換。**Filter** 一欄用於對各種篩選器進行必要的設置。**Filter** 一欄的左邊是一個 **Choose** 按鈕。點擊這個按鈕就可選擇 WEKA 中的某個篩選器。選定一個篩選器後，它的名字和選項會顯示在 **Choose** 按鈕旁邊的文字方塊中。用滑鼠左鍵點擊這個框，將出現一個 GenericObjectEditor（通用物件 編輯器）對話方塊。用滑鼠右鍵（或Alt+Shift+左鍵)點擊將出現一個功能表，你可從中選擇， 要麼在 GenericObjectEditor 對話方塊中顯示相關屬性，要麼將當前的設置字元複製到剪貼 板。

---

[3] 篩選器的英文原文是 filter，與資料庫術語中的篩選有關。但是 WEKA 中的 filter 不僅能提供篩選功能，還涵蓋了其他各種資料變換。—譯注。

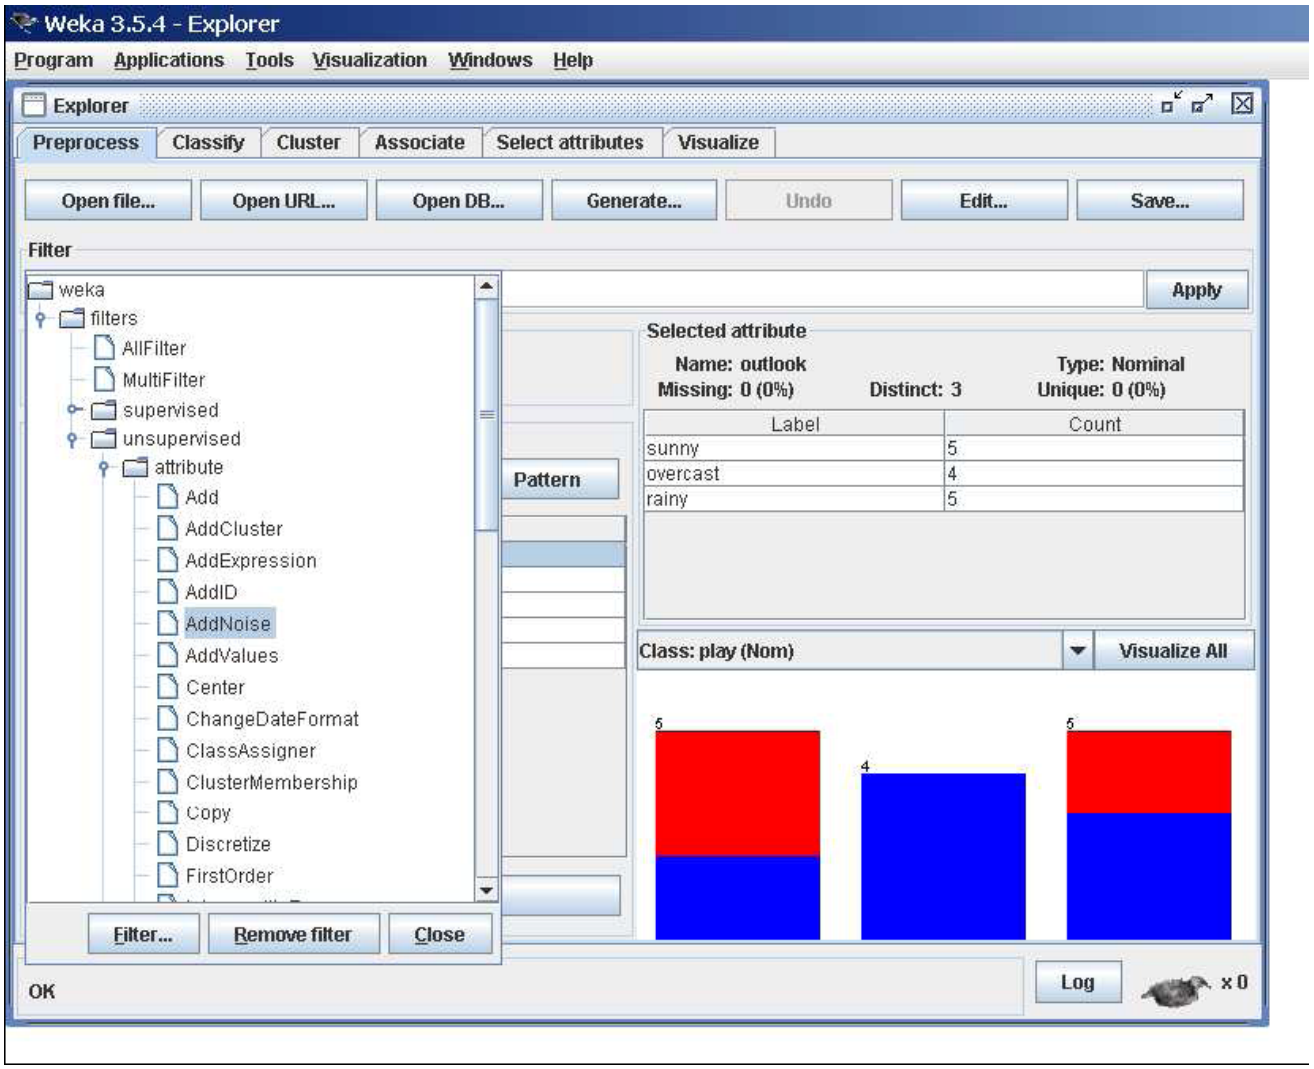

GenericObjectEditor 對話方塊

GenericObjectEditor 對話方塊可以用來配置一個篩選器。同樣的對話方塊也用於配置其他 物件，例如分類器（classifier）和 聚類器（clusterers）(見下文)。視窗中的欄位反映了可 用的選項。點擊它們中間的一個便可改變 filter 的設置。例如，某項設置可能是一串文本 字元，這時將字串輸入相應的文字方塊中即可。或者它可能會給出一個下拉清單，列出可供 選擇的幾個狀態。也可能是其他一些操作，根據所需的資訊而有所區別。如果把將滑鼠指 針停留在某個欄位上，會出現一個小提示來給出相應選項的資訊。而有關該篩選器和它的 選項的更多資訊可通過點擊 GenericObjectEditor 視窗頂部 **About** 面板中的 **More** 按 鈕來獲得。

除了 **More** 按鈕，某些物件也會在關於欄中顯示一些有關其功能的簡短描述。點擊 **More** 按鈕，會出現一個視窗來描述了不同的選項分別起什麼作用。有的還另外一個 **Capabilities** 按鈕，它能列出該物件可處理的屬性和 class 屬性的類型。

GenericObjectEditor 對話方塊的底部有4個按鈕。前兩個 **Open...** 和 **Save...** 允許存儲 對該物件的配置，以備將來之用。**Cancel** 按鈕用於直接退出，任何已作出的改變都將被 忽略。當前選擇的物件和設置令人滿意後，點擊 **OK** 返回到主 Explorer 視窗。

應用篩選器

選擇並配置好一個篩選器後，就可通過點擊 Preprocess 面板的 **Filter** 攔右邊的 **Apply** 按鈕將之應用於資料集上。然後 Preprocess 面板將顯示轉換過的資料。可點擊 **Undo** 按鈕取消改變。你也可使用 **Edit...** 按鈕在一個資料集編輯器中手動修改你的數據。最後，點擊 Preprocess 面板右上角的 **Save...** 按鈕將用同樣的格式保存當前的關係，以備將來使用。

注意：一些篩選器會依據是否設置了 class 屬性來做出不同的動作。（點擊長條圖上方那一欄時，會出現一個可供選擇的下拉清單。）特別的，“supervised filters”（監督式篩選器）需要設置一個 class 屬性， 而某些“unsupervised attribute filters”（非監督式屬性篩選器）將忽略 class 屬性。注意也可以將 Class 設成 None，這時沒有設置 class 屬性。

3 分類[4]

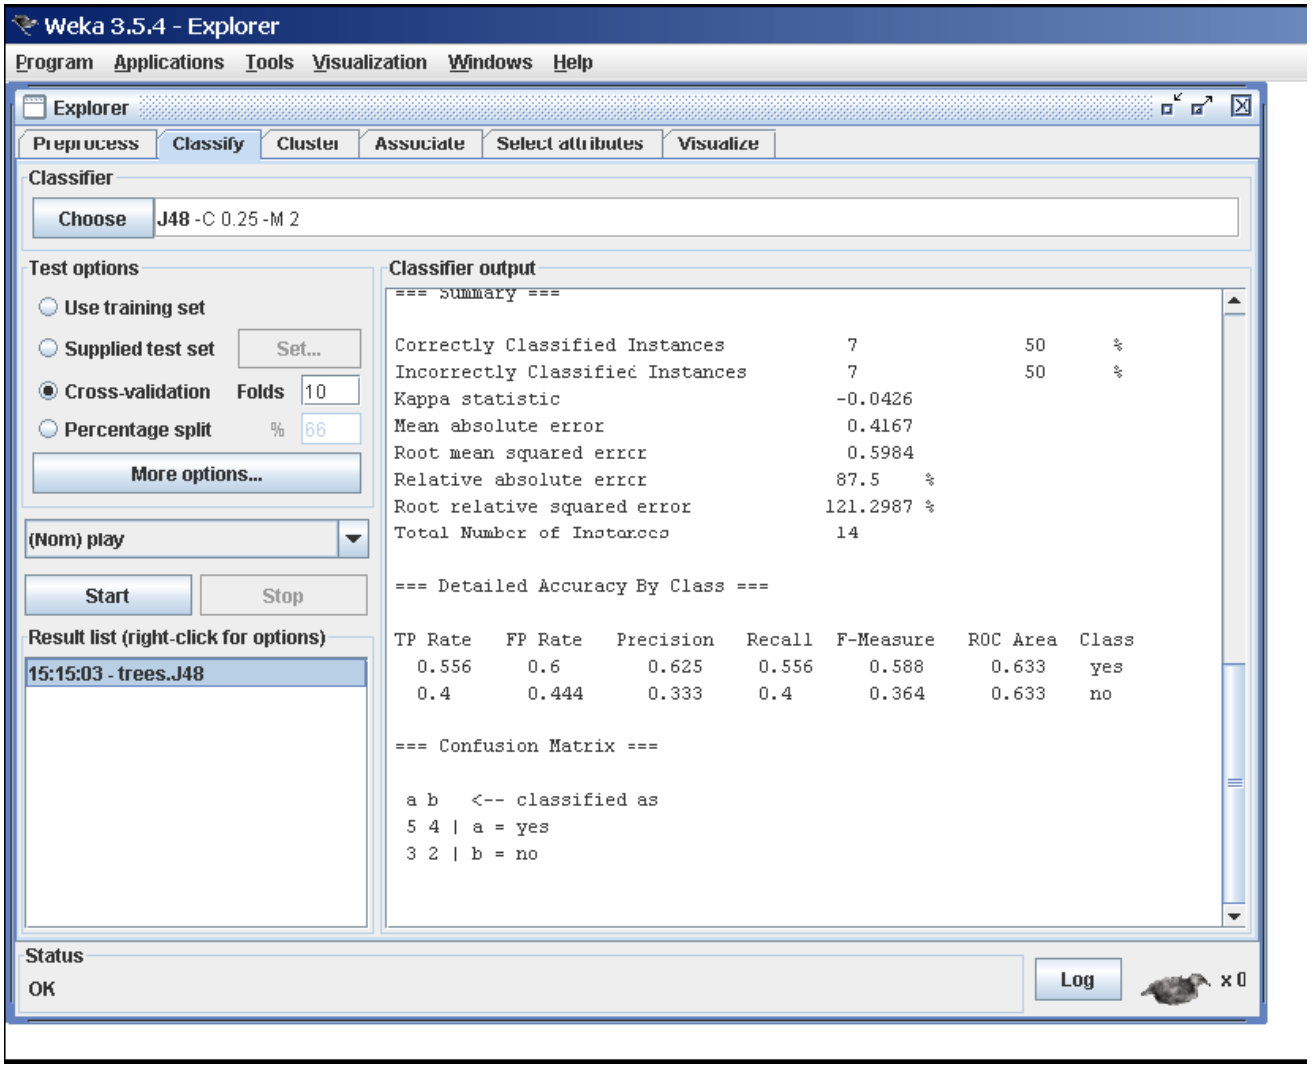

3.1 選擇分類器

在 classify 頁面的頂部是 **Classifier** 欄。這一欄中有一個文字方塊，給出了分類器的名稱和它的選項。左鍵點擊文字方塊會打開一個 GenericObjectEditor，可以像配置篩選器那樣 配置當前的分類器。右鍵（或Alt+Shift+左鍵)點擊也可以複製設置字元到剪貼板，或者在 GenericObjectEditor 中顯示相關屬性。**Choose** 按鈕用來選擇 WEKA 中可用的分類器。

3.2 測試選項

應用選定的分類器後得到的結果會根據 **Test Option** 一欄中的選擇來進行測試。共有四種測試模式：

1. **Using training set.** 根據分類器在用來訓練的實例上的預測效果來評價它。
2. **Supplied test set.** 從檔載入的一組實例，根據分類器在這組實例上的預測效果來評價它。點擊 **Set...** 按鈕將打開一個對話方塊來選擇用來測試的檔。
3. **Cross-validation.** 使用交叉驗證來評價分類器，所用的折數填在 **Folds** 文字方塊 中。

[4] WEKA 中的分類和回歸都放入了 classify 頁面中，相應的工具都叫做分類器（classifier）。參考4.3節。

4. **Percentage split.** 從資料集中按一定百分比取出部分資料放在一邊作測試用，根據分類器這些實例上預測效果來評價它。取出的資料量由 **%** 一欄中的值決定。 注意：

不管使用哪種測試方法，得到的模型總是從所有訓練資料中構建的。點擊 **More options** 按鈕可以設置更多的測試選項：

1. **Output model.** 輸出基於整個訓練集的分類模型，從而模型可以被查看，視覺化等。該選項預設詩選中的。
2. **Output per-class stats.** 輸出每個 class 的準確度/回饋率（precision/recall）和正確/錯誤（true/false）的統計量。該選項也是預設選中的
3. **Output evaluation measures.** 輸出熵估計度量。該選項預設沒有選中。
4. **Output confusion matrix.** 輸出分類器預測結果的混淆矩陣。該選項預設選中。
5. **Store predictions for visualization.** 記錄分類器的預測結果使得它們能被可視化表示。
6. **Output predictions.** 輸出測試資料的預測結果。注意在交叉驗證時，實例的編號不代表它在資料集中的位置。
7. **Cost-sensitive evaluation.** 誤差將根據一個價值矩陣來估計。**Set...** 按鈕用來指定價值矩陣。
8. **Random seed for xval / % Split.** 指定一個隨即種子，當出於評價的目的需要分割資料時，它用來隨機化資料。

3.3 Class 屬性

WEKA 中的分類器被設計成經過訓練後可以預測一個 class 屬性，也就是預測的目標。有的分類器只可用來學習分類型的 class 屬性；有的則只可用來學習數值型的 class 屬性 (回歸問題)；還有的兩者都可以學習。

預設的，資料集中的最後一個屬性被看作 class 屬性。如果想訓練一個分類器，讓它預測一個不同的屬性，點擊 **Test options** 欄下方的那一欄，會出現一個屬性的下拉清單以供選擇。

3.4 訓練分類器

分類器，測試選項和 class 屬性都設置好後，點擊 **Start** 按鈕就可以開始學習過程。分類器忙於訓練時，下方的小鳥會動來動去。可以通過點擊 Stop 按鈕，在任意時刻停止訓練過程。

訓練完成後，會發生幾件事。右邊的 **Classifier output** 區域會被填充一些文本，描述訓練和測試的結果。在 **Result list** 欄中會出現一個新的條目。接下來我們會觀察這個結果列表，但我們先來研究輸出的文本。

3.5 分類器輸出文本

Classifier output 區域的文本有一個捲軸以便流覽結果。按住 Alt 和 Shift 鍵，在這個區域點擊滑鼠左鍵，會出現一個對話方塊，讓你用各種格式（目前可用 JPEG 和 EPS） 保存輸出的結果。當然，可以通過放大 Explorer 視窗來獲得更大的顯示區域。輸出結果 可分爲幾個部分：

1. **Run information.** 給出了學習演算法各選項的一個清單。包括了學習過程中涉及 到的關係名稱，屬性，實例和測試模式。
2. **Classifier model (full training set).** 用文本表示的基於整個訓練集的分類模型。

所選測試模式的結果可以分解爲以下幾個部分：

3. **Summary.** 一列統計量，描述了在指定測試模式下，分類器預測 class 屬性的准確程度。

4. **Detailed Accuracy By Class.** 更詳細地給出了關於每一類的預測準確度的描述。
5. **Confusion Matrix.** 給出了預測結果中每個類的實例數。其中矩陣的行是實際的類，矩陣的列是預測得到的類，矩陣元素就是相應測試樣本的個數。

3.6 結果列表

在訓練了若干分類器之後，結果列表中也就包含了若干個條目。左鍵點擊這些條目可以在生成的結果之間進行切換流覽。右鍵點擊某個條目則會彈出一個功能表，包括如下的選 項：

1. **View in main window.** 在主視窗中顯示輸出該結果（就象左擊該條目一樣）。
2. **View in separate window.** 打開一個獨立的新視窗來顯示結果。
3. **Save result buffer.** 彈出一個對話方塊，使得輸出結果的文本可以保存成一個文本 檔。
4. **Load model.** 從一個二進位檔案中載入以前訓練得到的模型物件。
5. **Save model.** 把模型物件保存到一個二進位檔案中。物件是以 Java“序列化”的形式保存的。
6. **Re-evaluate model on current test set.** 通過 Supplied test set 選項下的 Set 按鈕指定一個資料集，已建立的分類模型將在這個資料集上測試它的表現。
7. **Visualize classifier errors.** 彈出一個視覺化視窗，把分類結果做成一個散點圖。其中正確分類的結果用叉表示，分錯的結果用方框表示。
8. **Visualize tree or Visualize graph.** 如果可能的話，把分類模型的結構用圖形來表示（例如決策樹（decision tree）和貝葉斯網路（Bayesian network）模型）。圖形視覺化選項只有在貝葉斯網路模型建好之後才會出現。在流覽決策樹圖形時，可以在空白處右擊滑鼠彈出一個功能表，也可以拖動滑鼠來拖動決策樹，還可以在 節點上按一下滑鼠查看它對應的訓練實例。Ctrl鍵+左鍵點擊會縮小圖形，Shift鍵+ 拖曳會得到一個方框並放大其中的圖形。這個圖形視覺化工具本身應該能夠解釋 它的作用。
9. **Visualize margin curve.** 創建一個散點圖來顯示預測邊際值。這個邊際值的定義爲：預測爲真實值的概率與預測爲真實值之外其它某類的最高概率之差。例如，提升式（boosting）演算法可以通過增加訓練資料上的邊際值來使得它在測試資料上 表現得更好。
10. **Visualize threshold curve.** 生成一個散點圖，以演示預測時改變各類之間的閥值後取得的平衡。例如說，默認的閥值是0.5，那麼一個實例要預測成爲“positive”，它是“positive”的預測概率必須大於0.5。這個曲線可以用來在 ROC 曲線分析中演示準確度/回饋率之間的平衡（正確的 positive 率對錯誤的 positive 率），也可用於其它類型的曲線。
11. **Visualize cost curve.** 生成一個散點圖，如 [1] 中所描述的那樣，給出期望價值（expected cost）的一個顯式表達。

在特定的情況下某些選項不適用時，它們會變成灰色。

4 聚類

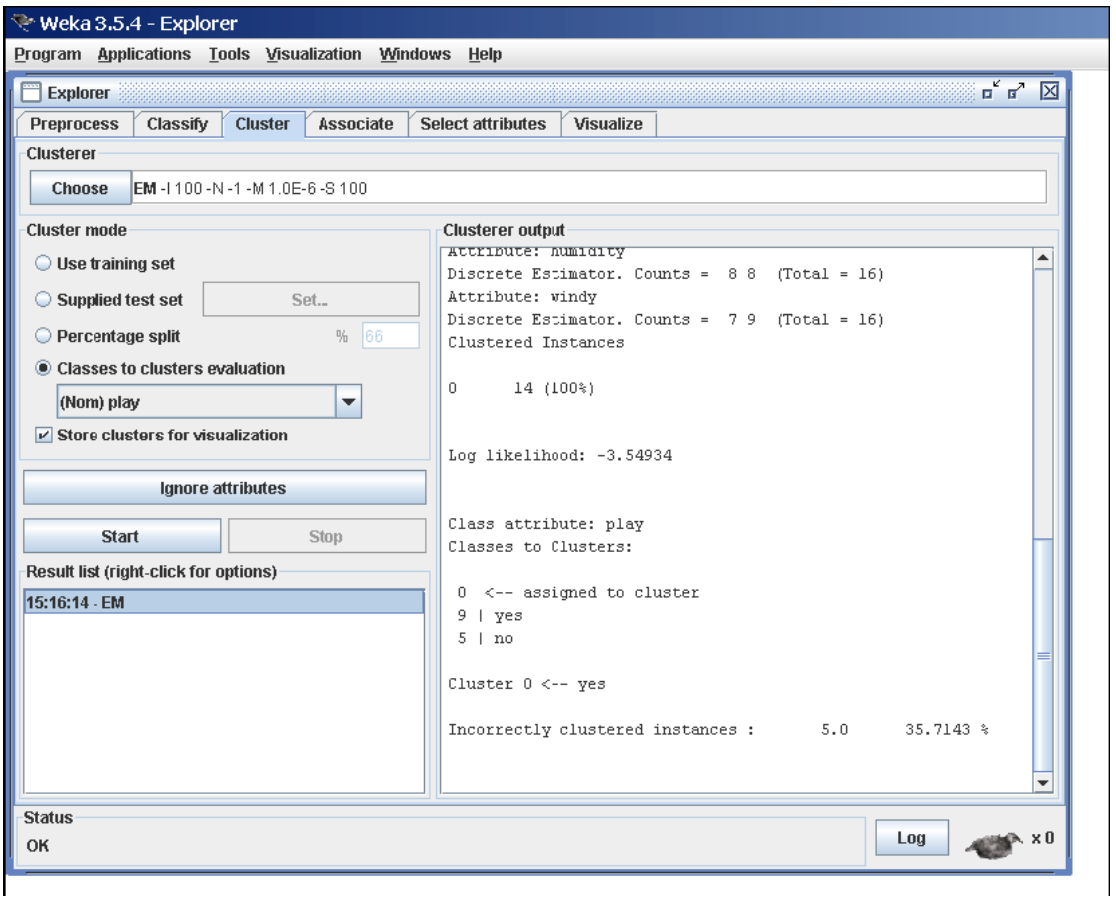

4.1 選擇聚類器（Clusterer）

現在我們應該熟悉選擇和配置物件的過程了。點擊列在視窗頂部的 **Clusterer** 欄中的聚類演算法，將彈出一個用來選擇新聚類演算法的 GenericObjectEditor 對話方塊。

4.2 聚類模式

Cluster Mode 一欄用來決定依據什麼來聚類以及如何評價聚類的結果。前三個選項和分類的情形是一樣的：**Use training set**、 **Supplied test set** 和 **Percentage split**（見4.1節）——區別在於現在的資料是要聚集到某個類中，而不是預測爲某個指定的類別。第四個模式，**Classes to clusters evaluation**，是要比較所得到的聚類與在資料中預先給出的類別吻合得怎樣。和 **Classify** 面板一樣，下方的下拉清單是用來選擇作爲類別 的屬性的。

在 Cluster mode 之外，有一個 Store clusters for visualization 的勾選框，該框決定了在訓練完演算法後可否對資料進行視覺化。對於非常大的資料集，記憶體可能成爲瓶頸時， 不勾選這一欄應該會有所幫助。

4.3 忽略屬性

在對一個資料集聚類時 經常遇到某些屬性應該被忽略的情況。**Ignore attributes** 可以彈出一個小視窗，選擇哪些是需要忽略的屬性。點擊視窗中單個屬性將使它高亮顯示，按住 SHIFT 鍵可以連續的選擇一串屬性，按住 CTRL 鍵可以決定各個屬性被選與否。點擊 **Cancel** 按鈕取消所作的選擇。點擊 **Select** 按鈕決定接受所作的選擇。下一次聚類演算法運行時，被選的屬性將被忽略。

4.4 學習聚類

Cluster 面板就像**Classify**面板那樣，有一個 **Start / Stop** 按鈕，一個結果文本的區域和一個結果列表。它們的用法都和分類時的一樣。右鍵點擊結果列表中的一個條目將彈出一個相似的功能表，只是它僅顯示兩個視覺化選項：**Visualize cluster assignments** 和 **Visualize tree**。後者在它不可用時會變灰。

5 關聯規則

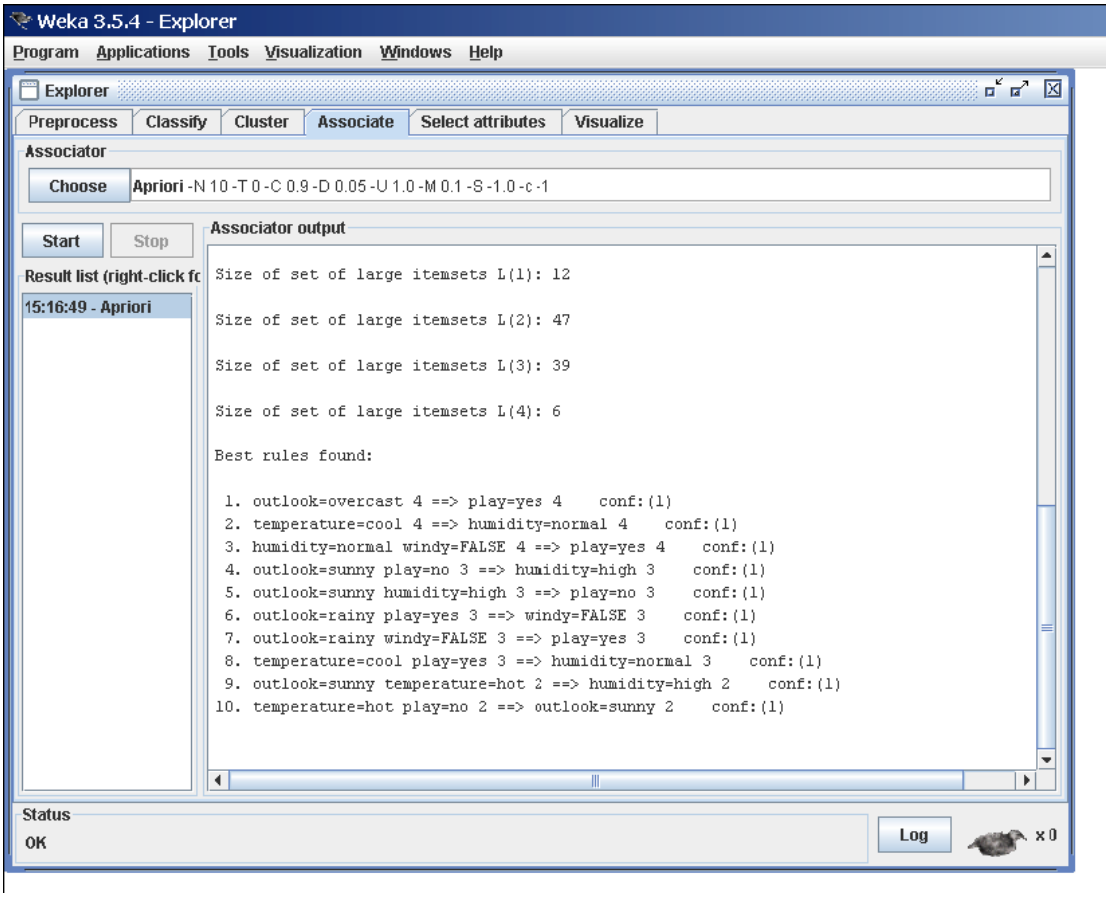

5.1 設定

這個面板包含了學習關聯規則的方案。這裡的學習器也可以跟其它面板的聚類器，篩選器和分類器一樣選擇和配置。

5.2 學習關聯規則

爲關聯規則學習器設置好合適的參數後，點擊 **Start** 按鈕。完成後右鍵點擊結果列表中的條目可以查看或保存結果。

6 屬性選擇

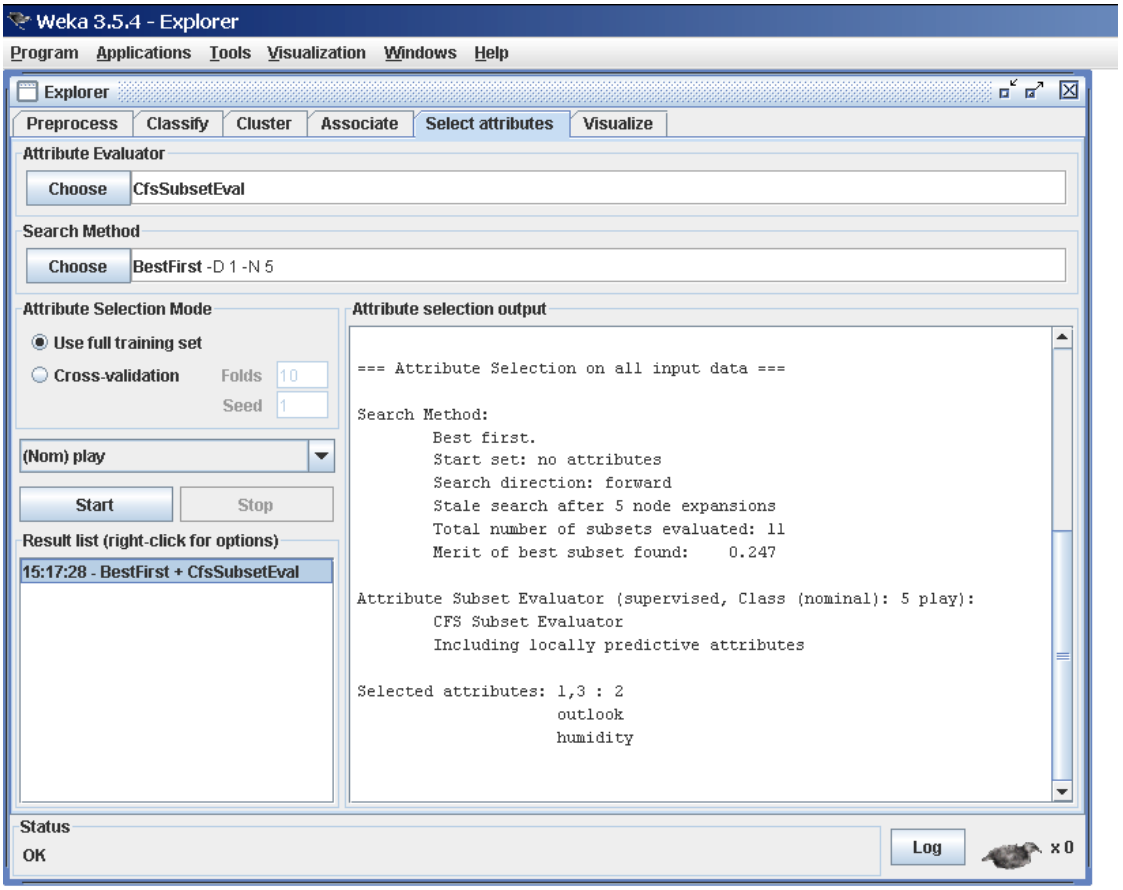

6.1 搜索與評估

屬性選擇是說搜索資料集中全部屬性的所有可能組合，找出預測效果最好的那一組屬性。爲實現這一目標，必須設定兩個東西：屬性評估器（evaluator）和搜索策略。評估器決定了怎樣給一組屬性安排一個表示它們好壞的值。搜索策略決定了要怎樣進行搜索。

6.2 選項

Attribute Selection Mode 一欄有兩個選項。

1. **Use full training set.** 使用訓練資料的全體好決定一組屬性的好壞。
2. **Cross-validation.** 一組屬性的好壞通過一個交叉驗證過程來決定。**Fold** 和 **Seed** 分別給出了交叉驗證的折數和打亂資料時的隨機種子。

和 **Classify** 部分（4.1節）一樣，有一個下拉清單來指定 class 屬性。

6.3 執行選擇

點擊 **Start** 按鈕開始執行屬性選擇過程。它完成後，結果會輸出到結果區域中，同時結果列表中會增加一個條目。在結果列表上右擊，會給出若干選項。其中前面三個（**View in main window**，**View in separate window** 和 **Save result buffe**）和分類面板中是一樣的。還可以視覺化精簡過的資料集（**Visualize reduced data**），或者，如果使用過主成分分析那樣的屬性變換工具，則能視覺化變換過的資料集（Visualize transformed data）。精簡過/變換過的資料能夠通過 **Save reduced data...** 或 **Save transformed data...** 選項來保存。

如果想在精簡/變換訓練集的同時進行測試，而又不使用在分類器面板中的

AttributeSelectedClassifier，那麼最好在命令列或者 SimpleCLI 中使用批量模式（“-b”）的 AttributeSelection 篩選器（這是一個 supervised attribute filter）。這一批量模式允許指定額外的輸入和輸出檔對（選項 –r 和 -s），處理它們的篩選器的設置是由訓練檔（由 –i 和 –o 選項給出）決定的。 下面
是 Unix/Linux bash 中的一個例子：

```
java weka.filters.supervised.attribute.AttributeSelection \
       -E "weka.attributeSelection.CfsSubsetEval " \
       -S "weka.attributeSelection.BestFirst -D 1 -N 5" \
       -b \
       -i <input1.arff> \
       -o <output1.arff> \
       -r <input2.arff> \
       -s <output2.arff>
```

注意：

- 每一樣末尾的反斜線告訴 bash 命令還沒有結束。使用 SimpleCLI 時必須把命令寫在同一行而不能使用反斜線。
- 這裡假設 WEKA 已經在 CLASSPATH 中了，否則還要加上 -classpath 選項。
- 整個篩選器的設置會在日誌中輸出，就像運行正規的屬性選擇時的設置一樣。

7 視覺化

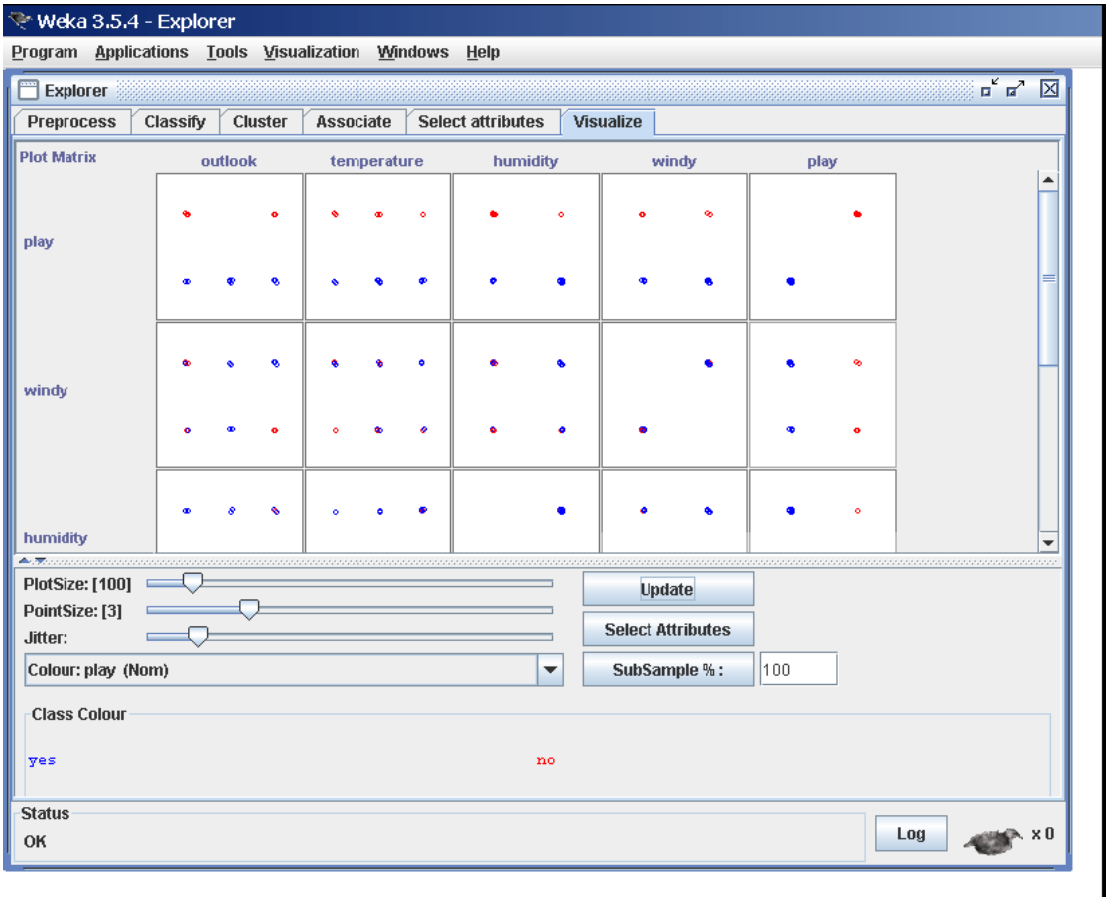

WEKA 的視覺化頁面可以對當前的關係作二維散點圖式的視覺化流覽。

7.1 散點圖矩陣

選擇了 **Visualize** 面板後，會爲所有的屬性給出一個散點圖矩陣，它們會根據所選的 class 屬性來著色。在這裡可以改變每個二維散點圖的大小，改變各點的大小，以及隨機地抖動（jitter）資料（使得被隱藏的點顯示出來）。也可以改變用來著色的屬性，可以只選擇一組屬性的子集放在散點圖矩陣中，還可以取出資料的一個子樣本。注意這些改變只有在點擊了 **Update** 了按鈕之後才會生效。

7.2 選擇單獨的二維散點圖

在散點圖矩陣的一個元素上點擊後，會彈出一個單獨的視窗對所選的散點圖進行可視化。（前面我們描述了如何在單獨的視窗中對某個特定的結果進行視覺化——例如分類誤差——這裡用了相同的視覺化控制項。）

資料點散佈在視窗的主要區域裡。上方是兩個下拉清單選擇用來選擇打點的坐標軸。左 邊是用作 x 軸的屬性；右邊是用作 y 軸的屬性。

在 x 軸選擇器旁邊是一個下拉清單用來選擇著色的方案。它可以根據所選的屬性給點著 色。在打點區域的下方，有圖例來說明每種顏色代表的是什麼值。如果這些值是離散的， 可以通過點擊它們所彈出的新視窗來修改顏色。

打點區域的右邊有一些水準橫條。每一條代表著一個屬性，其中的點代表了屬性值的分佈。這些點隨機的在豎直方向散開，使得點的密集程度能被看出來。在這些橫條上點擊可以改變主圖所用的坐標軸。左鍵點擊改變 x 軸的屬性；右鍵點擊改變 y 軸的。橫條旁

邊的“X”和“Y”代表了當前的軸用的那個屬性（“B”則說明 x 軸和 y 軸都是它）。

屬性橫條的上方是一個標著 **Jitter** 的游標。它能隨機地使得散點圖中各點的位置發生偏移，也就是抖動。把它拖動到右邊可以增加抖動的幅度，這對識別點的密集程度很有用。如果不使用這樣的抖動，幾萬個點放在一起和單獨的一個點看起來會沒有區別。

7.3 選擇實例

很多時候利用視覺化工具選出一個資料的子集是有說明的。（例如在 classify 面板的 UserClassifier（自訂分類器），可以通過互動式的選取實例來構建一個分類器。）

在 y 軸選擇按鈕的下方是一個下拉按鈕，它決定選取實例的方法。可以通過以下四種方式選取資料點：

1. **Select Instance.** 點擊各資料點會打開一個視窗列出它的屬性值，如果點擊處的點超過一個，則更多組的屬性值也會列出來。
2. **Rectangle.** 通過拖動創建一個矩形，選取其中的點。
3. **Polygon.** 創建一個形式自由的多邊形並選取其中的點。左鍵點擊添加多邊形的頂點，右鍵點擊完成頂點設置。起始點和最終點會自動連接起來因此多邊形總是閉合的。
4. **Polyline.** 可以創建一條折線把它兩邊的點區分開。左鍵添加折線頂點，右鍵結束設置。折線總是打開的（與閉合的多邊形相反）。

使用 **Rectangle**，**Polygon** 或 **Polyline** 選取了散點圖的一個區域後，該區域會變成灰色。這時點擊 **Submit** 按鈕會移除落在灰色區域之外的所有實例。點擊 **Clear** 按鈕會清除所選區域而不對圖形產生任何影響。

如果所有的點都被從圖中移除，則 **Submit** 按鈕會變成 **Reset** 按鈕。這個按鈕能使前面所做的移除都被取消，圖形回到所有點都在的初始狀態。最後，點擊 **Save** 按鈕可把當前能看到的實例保存到一個新的 ARFF 檔中。

参考文獻

[1] Drummond, C. and Holte, R. (2000) Explicitly representing expected cost: An alternative to ROC representation. *Proceedings of the Sixth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.* Publishers, San Mateo, CA.

[2] Witten, I.H. and Frank, E. (2005) *Data Mining: Practical machine learning tools and techniques. 2nd edition* Morgan Kaufmann, San Francisco.

[3] *WekaWiki* – `http://weka.sourceforge.net/wiki/`

[4] *WekaDoc* – `http://weka.sourceforge.net/wekadoc/`

[5] Ensemble Selection on *WekaDoc* – `http://weka.sourceforge.net/wekadoc/index.php/en:Ensemble_Selection`